

Inteligencia Artificial II

Juan Pablo Restrepo Uribe

Ing. Biomedico - MSc. Automatización y Control Industrial

jprestrepo@correo.iue.edu.co

2023


Institución Universitaria de Envigado

GAN

Las GAN confieren a las máquinas una especie de sentido de imaginación para poder crear algo nuevo desde cero



GAN



GAN

El objetivo principal de las GAN es generar datos desde cero. Para ello las GAN emplean dos redes neuronales y las enfrentan mutuamente. La primera red es el **generador** y la segunda es el **discriminador**.




GAN

Ambas redes fueron entrenadas con un mismo conjunto de datos

La primera debe intentar crear variaciones de los datos que ya ha visto (en el caso de los rostros de personas que no existen)

Debe crear variaciones de los rostros que ya ha visto.




Generative Adversarial Networks




Generative Adversarial Networks

- La tarea del **Discriminador** será decir si una cara es auténtica o falsa
- La tarea del **Generador** será la de crear fotos de caras que parezcan auténticas



Entrenando una GAN

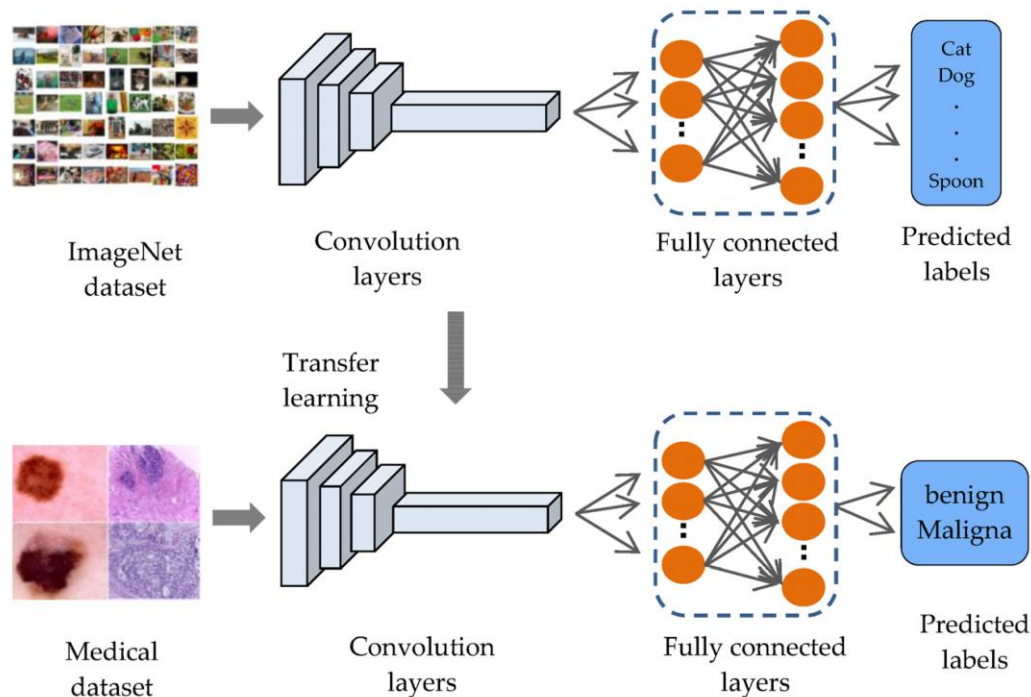
Al principio, es muy fácil para el discriminador acertar cuando dice cuáles fotos son reales. Esto es así porque al principio, las fotos creadas por la red neuronal generadora parecen aleatorias. Sin embargo, a medida que el generador mejora, la tarea de la red neuronal discriminadora se vuelve más difícil. Así pues, tanto el generador como el discriminador van mejorando simultáneamente.



<https://colab.research.google.com/drive/1hdTurtUkZr4QajmYnwd5vLTQKro69d3z>


Transfer learning

“El Transfer Learning, o aprendizaje transferido en español, se refiere al conjunto de métodos que permiten transferir conocimientos adquiridos gracias a la resolución de problemas para resolver otros problemas.”



Transfer learning

Los modelos utilizados en este campo necesitan grandes tiempos de cálculo y muchos recursos. Sin embargo, utilizando como punto de partida modelos pre-entrenados, el Transfer Learning permite desarrollar rápidamente modelos eficaces y resolver problemas complejos de Computer Vision o Natural Language Processing, NLP.



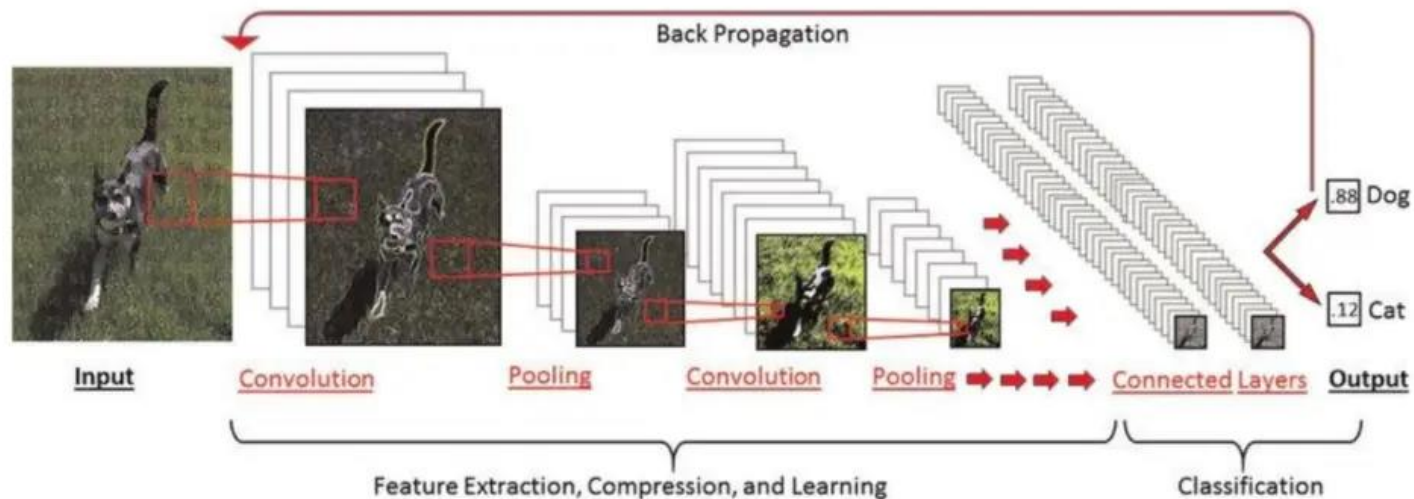
Tipos de Transfer learning

- Inductive transfer learning: La tarea fuente y objetivo son diferentes:
 - Se tienen muchos datos del dominio fuente
 - Se tienen pocos datos o ninguno del dominio objetivo
- Transductive transfer learning: Las tareas de la fuente y objetivo son las mismas, pero los dominios son diferentes:
 - Los espacios de atributos son diferentes en la fuente y en el objetivo
 - Los atributos son iguales pero las probabilidades marginales son diferentes ($P(X_f) \neq P(X_o)$)
- Unsupervised transfer learning: No se tienen datos etiquetados en ningún caso, las tareas son diferentes pero de alguna forma relacionadas

Utilización de modelos pre-entrenados como extractores de features

La arquitectura de estos modelos de Deep Learning se presenta frecuentemente bajo la forma de un compilado de capas de neuronas. Estas capas adquieren diferentes características en función del nivel en el que se sitúan. La última capa (generalmente una capa enteramente conectada, en el caso del aprendizaje supervisado), es utilizada para obtener el resultado final.

Utilización de modelos pre-entrenados como extractores de features

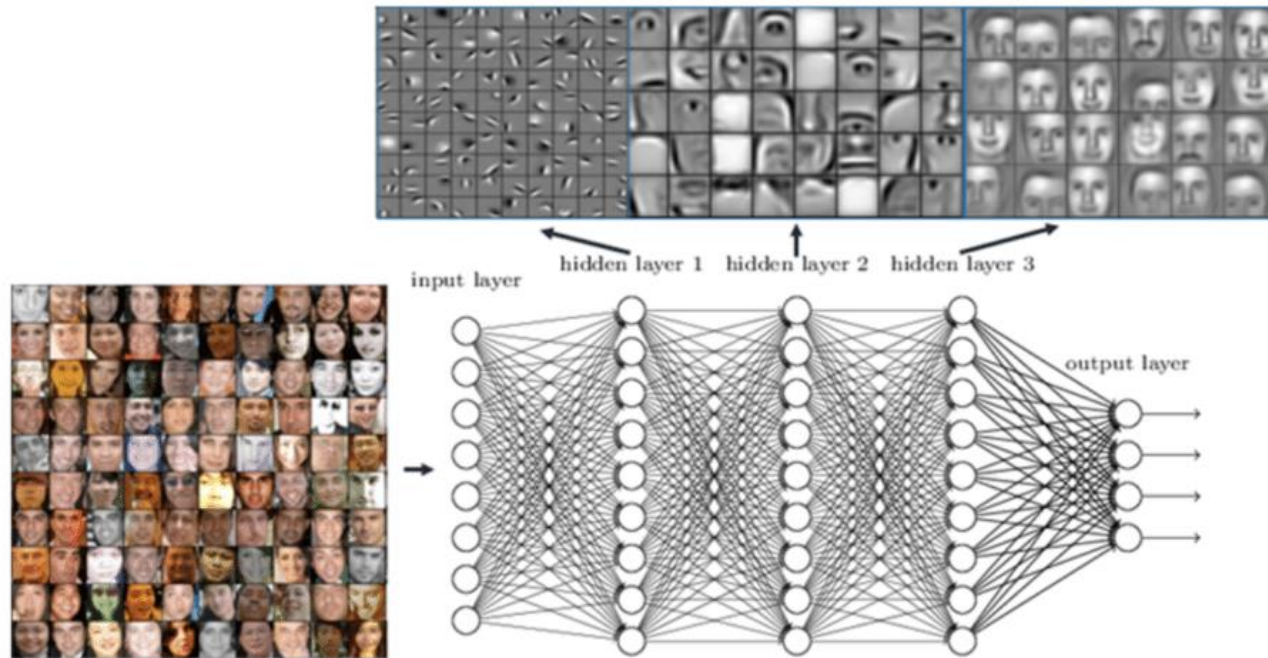


La idea es reutilizar una red pre-entrenada sin capa final. Esta nueva red funciona como un extractor de features fijas para realizar otras tareas.

Ajustes de modelos pre-entrenados

No solamente la última capa es reemplazada para realizar la clasificación o regresión, sino que también otras capas son re-entrenadas de manera selectiva. Las redes neuronales profundas son arquitecturas altamente configurables con diversos hiperparámetros. Además, mientras que las primeras capas captaron características generales, las últimas capas se concentran principalmente en la tarea específica a cumplir

Ajustes de modelos pre-entrenados



Fine-Tuning

El Fine-Tuning es una técnica de entrenamiento que consiste en la reutilización de arquitecturas de redes CNN predefinidas y preentrenadas.

En el aprendizaje por transferencia, se toma un modelo entrenado en una tarea para reutilizarlo en la resolución de otra, pero congelando los parámetros del modelo existente.


- Se carga el modelo entrenado y se congelan las capas preentrenadas para evitar la pérdida de información.
- Se añaden nuevas capas entrenables sobre las congeladas, que se entrenan con otro conjunto de datos.

Arquitecturas comunes

- **VGG16 y VGG19:** esta arquitectura, que fue una de las primeras en aparecer, fue introducida por Simonyan y Zisserman en 2014 con su artículo titulado Very Deep Convolutional Networks for Large Scale Image Recognition.
- **ResNet:** la arquitectura de ResNet la desarrolló He en 2015 para el transfer learning y fine tuning. El artículo se llama Deep Residual Learning for Image Recognition.
- **Inception V3:** este tipo de arquitectura lo introdujo en 2014 Szegedy en su artículo llamado Going Deeper with Convolutions.
- **Xception:** esta arquitectura la propuso François Chollet (el creador de Keras) y lo único que aporta respecto a Inception es que realiza las convoluciones de una forma óptima para que tarden menos tiempo.
- **SqueezeNet:** esta red es extremadamente ligera (sus pesos ocupan 5MB, en comparación de los 500MB de la VGG o los 100 de la Inception, por ejemplo) para transfer learning y fine tuning y consigue un accuracy de ~57% rank-1 o ~80% rank-5 con el ImageNet.

Transfer learning

Crear un modelo capaz de identificar la especie de una flor a partir de su imagen. Para esto, será posible utilizar las primeras capas de un modelo de red neuronal convolutivo AlexNet, que fue inicialmente entrenado sobre la base de imágenes ImageNet para clasificar imágenes.



<https://www.image-net.org/index.php>

Transfer learning

- AlexNet es una red neuronal convolucional con 8 capas de profundidad.
- Puede cargar una versión pre-entrenada de la red entrenada en más de un millón de imágenes desde la base de datos de ImageNet.
- La red pre-entrenada puede clasificar imágenes en 1000 categorías de objetos (por ejemplo, teclado, ratón, lápiz y animales).
- La red ha aprendido representaciones ricas en características para una amplia gama de imágenes. El tamaño de la entrada de imagen de la red es de 227 por 227.

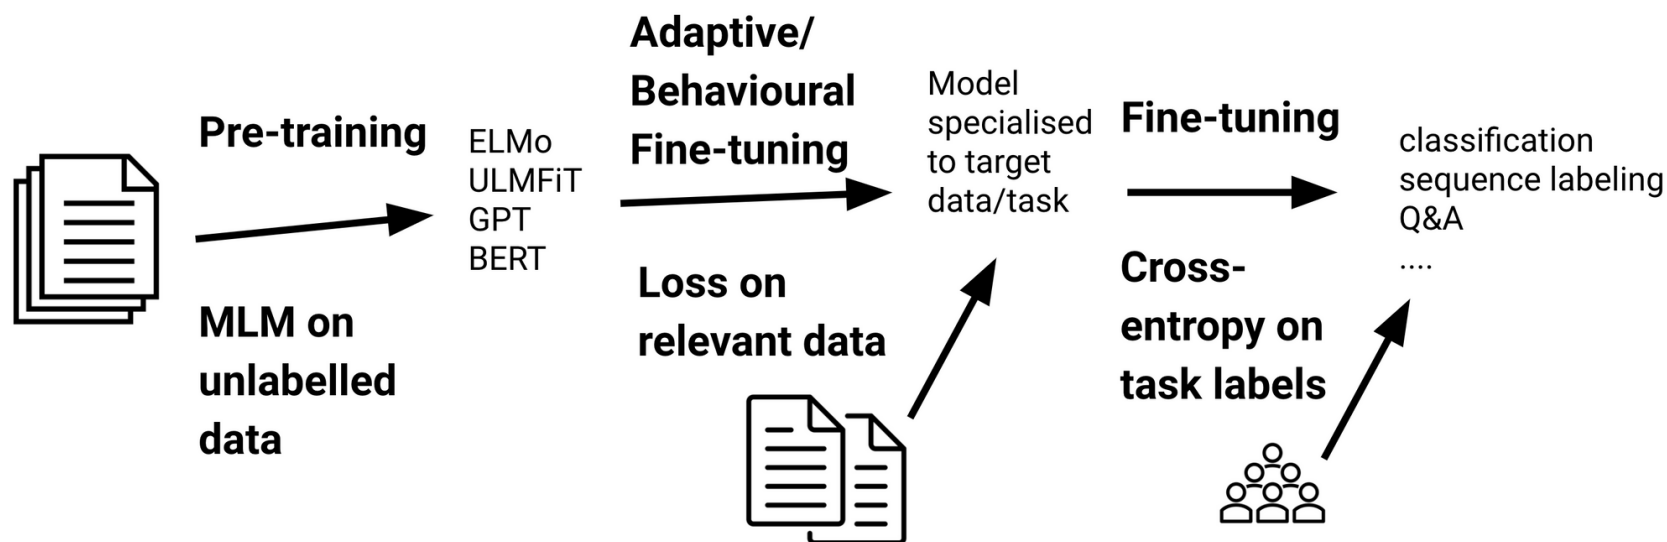
Transfer learning



<https://medium.com/practical-deep-learning/a-complete-transfer-learning-toolchain-for-semantic-segmentation-3892d722b604>

Fine -Tuning

El Fine-Tuning o ajuste fino permite tomar un modelo entrenado que realiza bien una determinada tarea y aprovechar todo su conocimiento para resolver una nueva tarea específica; aunque, por supuesto, con ciertas reglas.



Fine -Tuning

En el aprendizaje por transferencia, se toma un modelo entrenado en una tarea para reutilizarlo en la resolución de otra, pero congelando los parámetros del modelo existente. El proceso es el siguiente:

- Se carga el modelo entrenado y se congelan las capas preentrenadas para evitar la pérdida de información.
- Se añaden nuevas capas entrenables sobre las congeladas, que se entrenan con otro conjunto de datos.

Fine -Tuning

En el ajuste fino, en cambio, se toman los parámetros de la red existente para entrenarlos aún más y así realice la segunda tarea. Básicamente, se adapta la estructura del modelo y se entrena. Para ello, el procedimiento es este:

- Al modelo existente se le eliminan y agregan capas necesarias para la resolución de la nueva tarea.
- En la nueva estructura de modelo se congelan solo aquellas capas que provienen de la red original, cuyo conocimiento se desea conservar para el nuevo entrenamiento.
- Se procede a entrenar el modelo con los nuevos datos para la nueva tarea. Solo se actualizan los pesos de las capas nuevas.